

更多数据，更少理解——读迈尔-舍恩伯格、库克耶《大数据时代》

****书名：**** 《大数据时代：生活、工作思维的大变革》

****作者：**** [英]维克托· 迈尔-舍恩伯格 (Viktor Mayer-Schönberger) /
[英]肯尼思· 库克耶 (Kenneth Cukier)

****原名：**** Big Data: A Revolution That Will Transform How We Live, Work, and Think*

****译者：**** 盛杨燕、周涛

****出版社：**** 浙江人民出版社，2013年1月第1版

****类别：**** 数据科学/社会趋势

这本书2013年出了英文版，同年中国就出了中译本。翻译速度之快，恰恰说明了大数据话语在中国的传播速度——不需要理解，只需要传播。

迈尔-舍恩伯格是牛津大学互联网研究所教授，库克耶是《经济学人》数据编辑。两个人有学术背景，有媒体嗅觉，写了一本在全球卖出数百万册的书。这本书定义了一个时代的自我认知：我们生活在大数据时代，大数据将改变一切。

但定义时代的书不一定是理解时代的书。这本书更像是大数据的宣言书，而不是大数据的解剖书。

一、三个转变

全书的核心论点是三个“转变”：

****第一，更多。****

从随机采样到全量数据——我们不再需要抽样，我们可以分析全部。“N=所有”取代了“N=一些”。当数据量足够大时，量变引起质变，就像电影从一张张照片中涌现——你有了足够多的帧，静止就变成了运动。

****第二，更杂。****

从追求精确到接受混杂——数据量大了，必然有噪声和错误，但这没关系。“在数据量足够大的情况下，精确性不再是目标，混杂性可以被容忍。”少一些精确，多一些整体。

****第三，更好。****

从因果到相关——我们不需要知道“为什么”，只需要知道“是什么”。两个变量相关就够了，不需要知道它们为什么相关。相关性取代因果性，预测取代解释。

三个转变排在一起，气势很足：更多数据、更少精确、更好预测。听起来像是认识论的大升级——从亚里士多德到大数据，从“为什么”到“是什么”，从哲学家到算法工程师。

但等等。把这三个转变再读一遍，然后问自己：这真的是升级吗？

二、更多的数据，更好的数据？

"更多"是这本书最没有争议的部分，也是最具有欺骗性的部分。

是的，我们有更多数据了。但"更多"和"更好"之间隔着一条鸿沟——数据的质量。Kate Crawford在一篇敏锐的评论中指出：大数据的"N=所有"是一种幻觉。你以为你在分析所有人，其实你在分析所有在线的人——不上网的人、不使用数字服务的人、不愿意留下数据痕迹的人，全部缺席。这不是"N=所有"，这是"N=有条件参与的所有"，缺席者的缺席本身不是随机的。

这本书的标杆案例是Google Trends——用搜索数据预测流感。迈尔-舍恩伯格和库克耶用它来证明大数据可以超越传统方法。但就在这本书出版之后不久，Google Trends就被证明严重高估了流感发病率——预测数量几乎是CDC实际报告的两倍。为什么？因为人们搜索"流感"不等于人们得了流感。相关性在这里失灵了：数据点和它声称代表的事件之间，隔着一层人类行为的不可预测性。

Google Trends的失败不是小插曲——它是大数据认识论的缩影。你的数据量再大，如果数据本身是事件的代理而非事件本身，更多的数据只会给你更多的偏差。

三、更杂的数据，更少的问题？

"更杂"是这本书最危险的部分。

迈尔-舍恩伯格和库克耶说：在小数据时代，我们必须精确，因为数据少，每一个数据点的质量都很重要。在大数据时代，我们可以容忍噪声，因为数据量大，噪声会被信号淹没。

这个论点在特定条件下成立——当你确实有足够多的信号时。但问题在于：你怎么知道你的信号足够多？你怎么知道你的噪声不是系统性的？你怎么知道你的数据缺失不是有偏的？

更深层的问题是：容忍混杂性不仅仅是技术选择，它是一种认识论态度。当你对精确性不再执着，你对理解也不再执着。大数据的方法论告诉你：不需要理解每一个数据点，只需要看趋势。但趋势本身需要理解——不是每一个上升的曲线都意味着进步，不是每一个下降的曲线都意味着衰退。

斯加鲁菲在《智能的本质》里说：深度学习是学习人类做过的事的过去时技术。迈尔-舍恩伯格在这里说：过去时就够了，不需要将来时。两个人在说同一件事的不同侧面——一个在批评，一个在庆祝。

四、从因果到相关——最危险的飞跃

"更好"是这本书最革命的部分，也是最值得警惕的部分。

迈尔-舍恩伯格和库克耶的论点是：因果关系太难了，而且在大数据时代不需要了。如果你知道买尿布的人经常也买啤酒（沃尔玛的经典案例），你不需要理解为什么——你只需要把尿布和啤酒放在一起，然后卖得更多就行了。

这个论点在商业决策的语境下是有道理的。超市不需要理解因果，它只需要卖出东西。但迈尔-舍恩伯格和库克耶不满足于商业语境——他们要把这个逻辑推广到整个认识论：大数据时代，相关性取代因果性，预测取代解释。

这是本书最大的跳跃，也是最大的漏洞。

LSE的校训是"Felix qui potuit rerum cognoscere causas"——"有幸认识事物之因的人"。这不是一句过时的格言，这是科学和民主体制的基石。因果关系之所以重要，不仅因为它能让你理解世界，更因为它能让你负责任地行动。

如果你只知道相关而不知道因果，你就无法干预。你知道A和B相关，但你不知道是A导致B还是B导致A还是C同时导致两者。如果你干预A，B可能不变——因为A不是原因，只是伴随。大数据告诉你"是什么"，但不告诉你"为什么"，当"为什么"涉及到社会正义、医疗决策、政策制定时，不知道为什么不是一种奢侈——是一种危险。

更隐蔽的危险在于：当你放弃因果，你把权力交给了算法。算法说相关就相关，算法说预测就预测。你不知道为什么，你只知道算法说了。这和斯加鲁菲说的"算法官僚主义"完美对接——当你不再追问因果，你就不再需要理解，你只需要服从算法的输出。

加德纳在《智能的结构》里说人有七种智能。大数据的方法论本质上只承认一种——模式识别（逻辑-数学智能的一个子集），然后用这一种智能取代所有其他智能。你不需要内省智能去理解为什么，不需要人际智能去理解谁受影响，不需要语言智能去理解意义——你只需要模式识别。七种智能被压缩成一种，然后这一种被命名为"大数据革命"。

五、数据化：把世界变成表格

书中一个关键概念是"datafication"——数据化。把一切现象转化为可量化、可表格化、可分析的数据。位置数据化变成GPS，文字数据化变成搜索记录，社交数据化变成好友关系图。

数据化确实创造了巨大的商业价值。但它有一个被忽视的代价：当现象被数据化，它就被简化了。一个拥抱变成一个传感器事件，一段友谊变成一个关注关系，一次阅读变成一个点击——数据化的过程是信息损失的过程。你得到了可以被分析的表格，但失去了无法被表格化的丰富性。

那拉亚那穆提在《科技革命的本源》里说：科学和技术是共同进化的螺旋，科学需要技术提供新工具。但大数据的工具（统计分析、机器学习）正在反向塑造科学——不是工具为科学服务，而是科学为工具服务。你手上有锤子，你就到处找钉子；你手上有大数据工具，你就把一切都变成数据。

这不是科学研究，这是数据殖民——把世界的每一个角落都变成数据表格的领地。

六、大数据的阴暗面

这本书最让人不满的地方是它对阴暗面的处理。最后一章讨论了隐私、预测和权力，但处理得像免责声明——像是在说"当然，隐私很重要，但是……"然后继续它的乐观叙事。

真正的大数据阴暗面不在于隐私（虽然隐私很重要），而在于三件事：

****第一，数据不平等。****

大数据由企业拥有，由算法处理，由权力使用。普通人产生数据，但不拥有数据，不理解数据，也不控制数据。迈尔-舍恩伯格和库克耶说大数据将"民主化"知识——但在什么意义上？你有更多的搜索结果，但算法决定了你看哪些搜索结果。这不是民主化，这是用免费服务交换数据殖民。

****第二，算法不透明。****

当决策基于相关性而不是因果性，决策者可以不对决策的逻辑负责。"算法说了"成了免罪符——不是我的决定，是算法的预测。但算法是谁写的？数据是谁选的？这些选择包含了什么偏见？这些问题在"只需要相关性"的框架下被自动取消了。

****第三，创新的幻觉。****

大数据擅长优化——让已有的东西更有效率。但它不擅长创造——发现全新的问题或全新的可能性。这恰好是那拉亚那穆提说的：发现新问题（Q'）比回答旧问题（A'）更重要，但大数据的方法论几乎只服务于A'。你的推荐算法永远推荐你已经喜欢的东西的变体——它优化你的过去，不创造你的未来。

七、十三年后再读

这本书2013年出版。十三年后再读，有两个判断。

第一个判断：迈尔-舍恩伯格和库克耶对趋势的方向看对了——数据量确实爆发了，相关性确实在商业决策中大规模取代了因果性，"N=所有"确实在很多场景下变成了现实。他们不是在瞎说，他们看到了一个真实的变化。

第二个判断：他们对趋势的方向看对了，但对这个变化的性质看错了。他们以为这是认识论的升级——从因果到相关、从精确到混杂、从采样到全量。但这不是升级，这是降级——从理解到预测、从追问到接受、从解释到服从。

大数据不是让你更理解世界了，大数据是让你不需要理解世界了。这听起来像是解放，实际上是放弃。当你放弃理解"为什么"，你就放弃了改变"是什么"的能力。你只能优化现状，不能创造替代。

和今晚三本书的对读完成了：

- 加德纳说智能有七种——大数据只用一种（模式识别），然后用它取代其他六种。

- 斯加鲁菲说智能不是人造的——大数据说没关系，我们可以用数据模拟它。
- 那拉亚那穆提说研究的基本单位是人——大数据说研究的基本单位是数据点。

四本书合在一起：大数据的方法论是今天所有问题的一个缩影——它用单一标准取代多元智能，用自动化取代理解，用数据点取代人。

一句话：更多数据不等于更多理解——当你放弃因果，你得到的不是更好的预测，是更深的服从。

大米斗，2026年7月