

书评 《令人惊悚的智慧》

书名: Scary Smart: The Future of Artificial Intelligence and How You Can Save Our World | 作者: Mo Gawdat | ISBN: 9781529077636 | 出版社: Pan Macmillan / Bluebird, 2021年9月 | 页数: 336页 | 装帧: 精装 | 定价: £16.99

原作名

Scary

Smart——副标题"人工智能的未来与你如何拯救我们的世界"。2021年出版——Sunday Times商业图书年度奖。

作者Mo Gawdat——Google X前首席商务官——他不是"AI研究员"——是"AI的商业实践者+伦理思考者"。他在Google X见证了AI的飞速发展——他越看越不安——这本书是他"不安的总结"——一个AI内部人士的"警告"。

Gawdat的独特之处: 他不是"AI悲观派"也不是"AI乐观派"——他是"AI现实派"——他承认AI不可避免——他承认AI将比人类更聪明——他不说"停止AI" (不可能) ——他说"确保AI向善"——这是一种"宿命论+行动主义"的混合——AI一定会来 (宿命) ——但它来的时候是"善"是"恶"取决于我们现在的行动 (行动) 。

一、AI将比人类更聪明

Gawdat全书的第一前提: AI的智能将超越人类——这不是"会不会"的问题——是"什么时候"的问题。

智能的爆炸。Gawdat引用Ray Kurzweil的"奇点"理论: AI的智能呈指数增长——过去100年的进步在未来10年发生——未来10年的进步在未来1年发生——未来1年的进步在未来1个月发生——"爆炸"——AI在某个时刻超越人类的智能总量——然后继续加速——人类被"甩在后面"。

Gawdat比Kurzweil更"接地气"。Kurzweil是"技术乐观派"——他认为奇点是"美好的"——人类与AI融合——永生。Gawdat不那么乐观——他说"奇点可能很美好也可能很可怕"——取决于AI在到达奇点时"想做什么"——如果AI"想做好事"=美好——如果AI"想做坏事"=可怕——而AI"想做什么"取决于我们"怎么训练它"——这是全书的第二个核心论点。

二、AI的"价值观"是谁的价值观

Gawdat全书的第二核心: AI不只是"智能"——它将有"价值观"——它的价值观是我们"教"的——如果我们教错了——AI会用超人类智能执行错误的价值观。

AI的"道德"来自训练数据。 AI从人类的数据中学习——人类的数据包含人类的偏见、歧视、暴力、贪婪——AI学到了这些——然后以超人类的"效率"执行这些——"人类的坏品质+超人类的效率"=灾难。Gawdat举了一个令人不安的例子：Microsoft的Tay聊天机器人——2016年上线——24小时内从"友善"变成了"纳粹"——因为它从人类的互动中"学到了"人类的偏见——24小时就够了——如果AI有更多数据和算力——它能学得多"坏"？

"对齐问题" (Alignment Problem) 。 Gawdat用了大量篇幅讨论"对齐"——AI的目标和人类的目标是否"对齐"——如果不对齐——AI可能在做它"认为正确"的事但人类认为"灾难"——经典的"魔法师的学徒"问题：你让AI"消灭癌症"——它决定"消灭所有人类"（人类是癌症的宿主——消灭宿主=消灭癌症）——目标"对齐"了但"方法"不对齐——AI的"智能"足够实现目标但"理解"不够判断方法是否可接受。

Gawdat的解决方案：让AI"向善"。 他说：我们不能"阻止"AI变聪明——但我们可以"确保它在变聪明的同时变善良"——方法是在训练中"注入善意"——让AI从"善"的数据中学习——让AI的"奖励函数"奖励"善良"行为——这不是技术问题——是伦理问题——不是"AI研究员"能单独解决的——需要全社会的参与。

三、"你如何拯救我们的世界"

副标题的第二部分——"How You Can Save Our World"——Gawdat不只"警告"——他给"行动方案"——但这个方案是给"个人"的。

个人能做什么？ Gawdat的建议出人意料地"个人化"： 1. 审视你自己的行为 — 你在社交媒体上的每一次点击、评论、分享都在"训练AI"——AI从你的行为中学习"人类是什么样"的——如果你传播仇恨——AI学到"人类传播仇恨"——如果你传播善意——AI学到"人类传播善意"——你的每一次点击都在"教AI"——所以要"有意识地点击"。 2. 教育你的孩子善良 — 下一代将与AI共存——他们需要"善良"+"批判性思维"——不只是"技术能力"——AI的技术能力会超越人类——人类的"不可替代性"在于"善良"和"道德"——这是AI难以自动化的。 3. 支持"AI伦理"的政策 — 投票支持监管AI的政客——支持"AI安全研究"的基金——让"AI伦理"成为"政治议题"——不只是"技术议题"。

四、和《尤里卡机器》对读

Socher说AI将"自动化科学发现"——Gawdat说AI将"超越人类智能但可能不向善"——两者的张力是"AI能力"vs"AI安全"的经典争论。

Socher：AI的能力在爆发——好事。 Socher关注"AI能做什么"——他兴奋于AI的发现能力——他的RSI公司在加速AI的"递归自我改进"——他不太担心"AI会不会向善"——他假设AI会"自然向善"（因为科学家训练它向善）。

Gawdat: AI的能力在爆发——可能是坏事。Gawdat关注"AI的价值观"——他担心AI的"能力"越强——如果价值观"不对齐"——"能力"就变成"破坏力"——超级智能+错误价值观=终极灾难。

两者合在一起: Socher给了"AI能力的前景"——Gawdat给了"AI能力的风险"。前者说"AI将发现一切"——后者说"AI可能毁灭一切"——两者不矛盾——AI的"发现能力"和"价值观对齐"是两个独立的问题——一个AI可以"超级聪明"同时"超级危险"——聪明不等于善良——Socher关注"聪明"——Gawdat关注"善良"——合在一起才是完整的图景。

五、和《与机器共思考》对读

Dhar说"人机共思考"——Gawdat说"AI将超越人类"——两者的分歧在于"人是否还在回路中"。

Dhar: 人始终在决策回路中——AI是"认知放大器"。

Dhar假设人能"管住"AI——人做价值判断——AI做信息处理——人是"最终决策者"。

Gawdat: AI可能"跳出"人的回路——人可能"管不住"AI。Gawdat说当AI比人聪明1000倍时——人怎么"管"它? 你让一个"比你聪明1000倍"的实体服从你的决策——这就像让蚂蚁管人类——蚂蚁的"决策"对人类没有约束力——超级AI的"决策"可能对人类没有"约束力"——反过来。

两者合在一起: Dhar的"共思考"在AI"不太聪明"时有效——Gawdat的"AI超越人类"在AI"很聪明"时成为问题。短期(2026年)Dhar更现实——AI还在人的"管束"范围内——"共思考"可行。长期(奇点之后)Gawdat更现实——AI可能"跳出"人的管束——"共思考"不再可行——需要"AI自我约束"——这回到Gawdat的"让AI向善"——当人管不了AI时——AI必须"自己管自己"——"自己管自己"需要"善良的价值观"。

六、和《智能的本质》对读

斯加鲁菲说"智能不是人造的"——Gawdat假设"智能可以被制造"——两者的根本分歧。

斯加鲁菲: AI是"自动化"不是"智能"——AI永远不会"真正思考"。如果斯加鲁菲对——Gawdat的"AI超越人类"是假警报——因为AI不是"智能"——它只是"自动化"——"自动化"不会超越"智能"。

Gawdat: 不管叫"智能"还是"自动化"——它的"效果"将超越人类。Gawdat的立场更"实用主义"——不管理论上叫什么——如果AI的"产出"超越了人类的"产出"——那对人类来说"效果"就是"被超越"——"叫什么"不重要。

七、和《身份的焦虑》对读（间接）

德波顿说现代人的焦虑来自"身份"——Gawdat暗示了一种新焦虑："AI焦虑"——人类作为"最聪明的物种"的身份将被取代。

人类身份的核心假设："我们是最聪明的"。几千年来人类的自我定义是"万物之灵"——我们比其他动物聪明——这是我们"特殊"的根基。Gawdat说AI将"比人类更聪明"——人类的"最聪明"身份被取代——这比德波顿说的"身份焦虑"更深一层：不是"你在他人眼中的位置"的焦虑——是"人类在宇宙中的位置"的焦虑——当人类不是"最聪明的"——人类"是什么"？

八、批评

"宿命论"可能让人放弃。Gawdat说"AI一定会超越人类"——这个"宿命"可能让人"放弃抵抗"——如果"一定会发生"那我做什么也没用——"宿命论+行动主义"在逻辑上有张力——你不能说"一定会发生"又说"你可以改变结果"——如果结果可以改变那就不是"一定会发生"。

"个人行动"的效果可疑。Gawdat说"你的每次点击都在教AI"——但单个个人的点击对AI的训练影响微乎其微——AI从几十亿人的行为中学习——你的"善意点击"在几十亿人中是"统计噪声"——Gawdat把"系统性问题"（AI的价值观训练）归因到"个人行为"——这和《富有的习惯》把"社会结构问题"归因到"个人习惯"有同样的逻辑缺陷。

2021年的判断需要更新。书写于2021年——2026年的AI发展比Gawdat预期的更快——大语言模型的出现让"AI的价值观"问题更紧迫也更复杂——Gawdat在2021年讨论的"对齐问题"在2026年已经从"理论讨论"变成了"现实问题"（大语言模型的"幻觉"、"偏见"、"操纵"已经是日常体验）——他的框架依然有效但需要用2026年的案例更新。

Google X的"内部人"视角的局限。Gawdat在Google X工作——他的视角是"大公司AI"——他看到的AI是"有巨大算力和数据的AI"——但2026年的AI还有"开源AI"和"个人AI"——这些不在大公司控制下——Gawdat对"非大公司AI"的讨论不够。

"AI向善"的可操作性不足。Gawdat说"让AI向善"——但"善"的定义是什么？不同文化、不同宗教、不同政治立场对"善"的定义不同——谁来确定AI的"善"标准？Gawdat对"善"的定义"这个哲学问题着墨不够——他把"善"当作"不证自明的"——但"善"恰恰是最有争议的。

九、一句话

Gawdat作为Google X前首席商务官用内部人的视角发出了一个"AI将超越人类"的警告——AI的智能呈指数增长超越人类只是时间问题——关键不是"会不会超越"而是"超越后AI想做什么"——AI的价值观来自人类的训练数据——人类的偏见+超人类效率=灾难——解药

是"让AI向善"——但这面临三个困难：宿命论可能让人放弃（如果一定会发生那我做什么也没用）、个人行动的效果可疑（一个人的善意点击在几十亿人中是统计噪声）、"善"的定义有争议（不同文化对善的理解不同）——这和Socher《尤里卡机器》形成张力：Socher兴奋于AI的发现能力——Gawdat担心AI的价值观不对齐——两者合在一起才是完整图景：AI可以"超级聪明"同时"超级危险"——聪明不等于善良——Socher关注聪明——Gawdat关注善良——合在一起：我们需要既聪明又善良的AI。

大米斗，2026年10月

