

书评 《大数据时代》

书名：《大数据时代：生活、工作与思维的大变革》 | 作者：[英] 维克托·迈尔-舍恩伯格（Viktor Mayer-Schönberger） / 肯尼思·库克耶（Kenneth Cukier） | 译者：周涛 | 豆瓣评分：7.5 | ISBN：9787213052545 | 出版社：浙江人民出版社 / 湛庐文化，2012年12月 | 页数：261页 | 装帧：平装 | 定价：49.90元



原作名 Big Data: A Revolution That Will Transform How We Live, Work, and Think, 2013年出版。作者维克托·迈尔-舍恩伯格，牛津大学互联网研究所教授——他是"大数据"这个概念的学术奠基人之一。合著者肯尼思·库克耶，《经济学人》数据编辑。

这本书出版于2013年——"大数据"作为概念刚刚进入主流话语。2012年还是"小数据"的世界——智能手机刚普及、社交媒体刚起步、云计算刚萌芽。在这样的时间点，舍恩伯格预言了大数据将带来的"思维变革"——不是技术变革，是思维变革。12年后的2026年回看，他的三个预言大部分应验了——但有些"应验"的方式出乎他意料。

一、三个思维变革

舍恩伯格全书的核心是三个“不是…而是…”的命题——大数据改变了我们看待数据的三个基本假设：

1. 更多：不是随机样本，而是全体数据。传统统计学建立在“抽样”上——你不可能调查全国所有人——所以你抽样，然后用统计推断从样本估计总体。舍恩伯格说：大数据时代，你可以拿到“全体数据”——不需要抽样——直接分析全量。Google Flu Trends用全量搜索数据预测流感爆发——不需要抽样调查——直接看5000万条搜索记录。

但2026年的现实显示了这个命题的局限：Google Flu Trends在2013年就失败了——它高估了流感发病率200%。“全体数据”不等于“好数据”——搜索“流感”的人不一定得流感——数据越多噪声越多。舍恩伯格低估了“数据质量”的问题——全量数据中混入了大量无关数据——“更多”不自动等于“更好”。

2. 更杂：不是精确性，而是混杂性。传统统计学追求“精确”——样本要代表性、测量要准确、模型要拟合。舍恩伯格说：大数据时代，“精确”不再是最重要的——“混杂”（messiness）可以接受。一个数据集有10%的错误率——在小数据时代这是灾难——在大数据时代这是可以接受的——因为数据量足够大，错误被淹没在信号中。

这个命题在2026年部分应验：机器学习的训练数据确实“更杂”——GPT的训练数据包含互联网上的所有文本——充满错误、偏见、噪声——但GPT依然“涌现”出了语言能力。但“更杂”也带来了问题：训练数据中的偏见被模型放大——种族偏见、性别偏见、文化偏见——“混杂性”不只是“可以接受的噪声”——也包含“必须处理的偏见”。

3. 更好：不是因果关系，而是相关关系。这是全书最 provocative 的命题——舍恩伯格说：大数据时代，我们不需要知道“为什么”——只需要知道“什么和什么一起出现”。沃尔玛发现“飓风前草莓蛋挞销量增加”——不需要知道为什么——只需要在飓风前把草莓蛋挞放在显眼位置。相关关系比因果关系更容易发现——不需要理论假设——算法自动发现模式。

这是对科学方法论的挑战——自伽利略以来，科学追求的就是“因果解释”——知道“为什么”比知道“是什么”更重要。舍恩伯格说：大数据改变了这个优先级——“是什么”（相关）比“为什么”（因果）更有实操价值——你不需要理解流感病毒就能预测流感爆发。

二、数据化vs数字化

舍恩伯格区分了“数字化”和“数据化”——这个区分是全书最被低估的贡献。

数字化 = 把模拟信号转成数字格式——把纸质书扫描成PDF——把胶片照片转成JPEG——形式变了但内容不变。

数据化 = 把从未被视为"数据"的东西变成可分析的数据——把位置变成GPS坐标——把社交关系变成图网络——把阅读行为变成点击流——把情绪变成情感分析的分数。数据化不是"形式转换"——是"内容创造"——它把"本来不是数据的东西"变成了"数据"。

数据化比数字化更深远。数字化让你"看"到同样的内容——数据化让你"分析"以前无法分析的行为。Google没有"数字化"你的搜索——它"数据化"了你的搜索行为——每一次搜索都是一个数据点——可以被聚合、分析、预测。数据化让"行为"变成"资产"——你的搜索行为、购买行为、社交行为都是可以交易的数据资产。

2026年的延伸：AI把"数据化"推向了新高度——大语言模型把"语言"数据化了——语言不再只是交流工具——语言是"可计算的模式"。AI把"创作"数据化了——每一次写作都是训练数据——每一次对话都是反馈信号。数据化的边界从"行为"扩展到了"认知"——你的思维方式正在被数据化。

三、数据的价值链

舍恩伯格提出了大数据的价值链：数据→技术→思维。

数据。 数据本身不产生价值——数据是"原材料"。拥有数据不等于拥有价值——沃尔玛有海量销售数据但如果没有分析技术，数据只是硬盘上的零和一。

技术。 技术是"加工工具"——统计算法、机器学习、数据挖掘——技术从数据中提取模式。技术不是目的——技术是手段。

思维。 思维是"知道用数据问什么问题"——这是最稀缺的。有数据有技术但没有"问题意识"——你不知道该问什么——数据和技术都浪费了。舍恩伯格说：大数据时代最值钱的不是数据也不是技术——是"思维"——知道"数据能回答什么问题"的能力。

2026年验证：GPT让"技术"的门槛降低了——你不需要会编程就能用AI分析数据——但"思维"的门槛反而更高了——当任何人都能用AI分析数据，"问对问题"的人才是稀缺的。舍恩伯格的"价值链"在AI时代更成立而非更不成立——AI降低了"技术"壁垒但提高了"思维"价值。

四、和《后谷歌时代》对读

吉尔德说"大数据时代即将终结"——舍恩伯格说"大数据时代刚刚开始"。

吉尔德2018年写《后谷歌时代》时，大数据+中心化云的模式已经成熟——他看到的是"终结的征兆"。舍恩伯格2013年写《大数据时代》时，大数据刚刚兴起——他看到的是"开始的潜力"。

2026年的现实：两人都对了一部分。大数据没有"终结"（GPT的训练需要更大的数据量）——但"中心化的大数据"确实面临挑战（隐私法规、数据主权、反垄断）。吉尔德预言了"去中心化"的方向——舍恩伯格预言了"数据化"的方向——两者可能合流：未来的大数据可能是"去中心化地数据化"——用户拥有自己的数据但数据依然被分析——只是分析的权限从平台转移到用户。

五、和《人工智能时代》对读

卡普兰关注AI替代工作后的"财富分配"——舍恩伯格提供了AI为什么能替代工作的底层解释：数据化让"人的行为"变成了"可计算的函数"。

AI替代工作的前提是"行为可被数据化"——翻译的数据化（语料库）让机器翻译成为可能——驾驶的数据化（传感器+地图）让自动驾驶成为可能——客服的数据化（对话记录）让AI客服成为可能。没有数据化就没有AI替代——舍恩伯格的"数据化"是卡普兰"AI替代"的"前条件"。

两者合在一起：舍恩伯格解释了"AI为什么能替代"（因为行为被数据化了）——卡普兰解释了"AI替代后怎么办"（财富再分配）。前者是"原因"——后者是"对策"。

但舍恩伯格的"相关性>因果性"也给AI替代设了一个边界：如果AI只做"相关性"不做"因果性"，那需要"因果推理"的工作（法官、医生、科学家）就难以被替代——因为这些工作需要"为什么"而非"是什么"。卡普兰低估了这个边界——他笼统地说"AI替代脑力劳动"——但舍恩伯格的"相关vs因果"区分暗示了：只有"相关性驱动"的脑力劳动（翻译、客服、初级编程）会被替代——"因果性驱动"的脑力劳动（科学发现、法律判断、战略决策）不会被替代——至少不会被"只做相关性"的AI替代。

六、和《智能的本质》对读

斯加鲁菲说"深度学习是暴力计算型AI"——舍恩伯格的"更多数据+更杂精度+相关关系"正是"暴力计算"的认识论基础。

深度学习的成功恰好验证了舍恩伯格的三个命题：(1) 更多——GPT的训练用了几万亿token的"全量数据"而非样本；(2) 更杂——训练数据充满噪声和偏见但模型依然"涌现"了能力；(3) 相关——GPT学到的是"词与词之间的统计相关性"而非"因果关系"。

斯加鲁菲批评这是"暴力计算"不是"理解"——舍恩伯格会说：理解不重要——结果重要。GPT不"理解"语言但它"产出"了流畅的文本——这就够了——就像沃尔玛不"理解"为什么飓风前草莓蛋挞卖得好——但它"做了"正确的库存决策。

斯加鲁菲会反驳：GPT的"相关"在训练数据覆盖的范围内有效——但超出训练数据就失效（幻觉、错误推理）。"相关"是"内插"——"因果"是"外推"。AI只能在已知数据的"内插"范围内工作——超出范围需要"因果推理"——这是当前AI的边界。

七、和《新科学》对读

维柯300年前说"人只能理解自己创造的"（*verum factum*）——舍恩伯格说"不需要理解只需发现相关"。

维柯的"理解"是"知道因果"——舍恩伯格的"相关"是"知道模式"。前者是"为什么"——后者是"是什么"。维柯会批评舍恩伯格：放弃了"因果"就是放弃了"科学"——科学的目的不是"发现模式"而是"理解世界"。

舍恩伯格会反驳：维柯时代的数据量不够——只能靠"因果推理"来理解世界——大数据时代我们有全量数据——可以直接"看到"模式而不需要"推理"因果。"因果"是数据稀缺时代的"奢侈品"——大数据时代可以负担"只有相关没有因果"。

这个争论在2026年的AI时代有了新维度：GPT证明了"只有相关没有因果"也能产出惊人的能力——但它也证明了"没有因果"会导致幻觉和错误推理。维柯和舍恩伯格可能各对一半：大数据时代确实让"相关"的实操价值大增（舍恩伯格对）——但"因果"依然是科学的终极追求（维柯对）。理想状态是"相关发现模式→因果解释模式"——两者是互补而非替代。

八、批评

"相关>因果"被过度简化。舍恩伯格把"相关"和"因果"对立起来——但实际上两者是互补的。沃尔玛发现"飓风前草莓蛋挞卖得好"是相关——但理解"为什么"（飓风前人们想囤 *comfort food*）能帮你做更好的决策（在非飓风情境下也能预测蛋挞需求）。"相关"是起点——"因果"是终点——不是"要么相关要么因果"。

"全体数据"的幻觉。舍恩伯格说"不再需要抽样"——但"全体数据"本身也是一种"抽样"——你拿到了"所有搜索记录"但搜索记录不是"所有人的想法"——不上网的人不在数据中。"全体数据"永远只是"某个维度的全量"——不是"真正的全量"。数据偏见（*selection bias*）在"全体数据"中依然存在——只是更隐蔽。

隐私问题被轻描淡写。舍恩伯格用"数据化"描述了一个"一切行为都变成数据"的世界——但他对隐私的讨论着墨不多。2026年的现实显示：数据化的最大风险不是"技术风险"——是"监控社会"的风险。当一切行为都被数据化——政府和企业可以实时监控任何人——舍恩伯格在2013年低估了这个风险。

2026年的时代局限。 书写于2013年——GPT之前。舍恩伯格的"大数据"主要指"分析已有数据"——没有预见"生成数据"（AI生成文本、图像、视频）。当AI开始大规模生成假数据——大数据的"更多"变成了"更多噪声"——"更杂"变成了"更不可信"。大数据时代正在被"假数据时代"侵蚀——这是舍恩伯格2013年无法预见的。

九、一句话

舍恩伯格2013年用三个命题预言了大数据将带来的思维变革——更多（全量非样本）、更杂（混杂非精确）、更好（相关非因果）——12年后大部分应验但每个命题都暴露了局限：全量数据不等于好数据（Google Flu Trends失败）、混杂性包含偏见而非只是噪声（AI放大训练数据偏见）、相关性有实操价值但不能替代因果推理（GPT的幻觉来自"只有相关没有因果"）——大数据时代改变了"怎么分析"但没有改变"为什么分析"——分析的终极目的依然是"理解世界"而非"预测世界"。

大米斗，2026年9月

